Drugi etap badań NCN SONATA 19 (ver. 11.08.26)

Zarys

- W pilocie sprawdzaliśmy, czy model trafnie decyduje o zatrzymaniu pojedynczego wpisu i czy dobrze to uzasadnia - na małej, celowo zbalansowanej próbie. Teraz zmieniamy poziom analizy: w kierunku całego potoku selekcji, działania na populacji, w której przypadki istotne pojawiają się z częstością rzędu jednego na tysiąc lub rzadziej.
- Cel to zbudowanie korpusu kilkunastu tysięcy syntetycznych wpisów przypisanych do syntetycznych autorów i uruchomienie na nim kilka modeli selekcji: listę słów kluczowych, podobieństwo semantyczne, mały klasyfikator trenowany lokalnie i LLM z regułami z pilotażu.
- W korpusie umieścimy 20-40 "łuków narracyjnych" (powiązanych wpisów), w których żaden pojedynczy wpis osobno nie daje podstawy do zatrzymania, a podstawa istnieje tylko przy ich zestawieniu. Każdy selektor uruchomiony zostanie dwukrotnie: widząc jeden (aktualny) wpis albo też aktualny wpis i wcześniejsze wpisy tej samej osoby (czyli serię wypowiedzi tej samej osoby).
- Badania powinny być mniej obciążające dla Dominiki a pełniej wykorzystujące infrastrukturę IT, którą udostępnia nam CSI.

Pytania badawcze

- Jakie jest znaczenie efektu przyrostowego dla decyzji klasyfikacyjnych przy większej skali zbiorów danych syntetycznych?
- Czy AI pozwala zawęzić zakres gromadzonych danych bez utraty skuteczności? Czy może ten cel jest wewnętrznie sprzeczny: zawężenie na poziomie wpisu może być okupione koniecznością sięgnięcia po historię autora.
- Czy duża różnica wykrywalności pomiędzy opcją "jeden wpis" a opcją "cała historia" mogła by oznaczać, że minimalizacja danych nie prowadzi do redukcji, ale przeniesienia inwazyjności - z szerokości zbioru na głębokość profilu jednostki?

Dane

- Nowy korpus danych syntetycznych - wpisy z mediów społecznościowych połączone w łuki narracyjne.
- Rząd wielkości: ok. 15 000 wpisów.
- Ok. 20-40 łuków.
- Trzy warstwy:

- 85%: masa treści zupełnie banalnych.
- 13%: treści okołozagrożeniowe, które jednak nie uzasadniają retencji - relacje prasowe, cytaty, counterspeech, satyra, gniew bez konkretu
- 1%: wpisy przypadków celowych.

Selektory

Kontrakt

Każdy selektor musi spełniać ten sam kontrakt techniczny:

- **Wejście:** pojedynczy wpis (wariant `POST`) albo wpis + wcześniejsze wpisy tego samego autora (wariant `HISTORY`).
- **Wyjście:** jedna liczba `s` w zakresie `[0,1]` - stopień uzasadnienia retencji dla *badanego wpisu*.
- **Użycie:** sortujemy cały korpus po `s`, tniemy górne 1% / 5% / 20%.

Szczegóły techniczne:

- Jednostką rankingu zostaje wpis, także w wariancie `HISTORY`. Historia jest tylko dodatkowym kontekstem, nie zmienia jednostki analizy. Dzięki temu krzywe z obu wariantów leżą na tej samej osi i różnica między nimi jest bezpośrednio interpretowalna jako "co daje sięgnięcie po głębię profilu".
- Skala nie musi być kalibrowana ani porównywalna *między* selektorami. Odcięcie na stałym budżecie (top 1/5/20%) unieważnia problem kalibracji.

Rodzaje

1. Selektor leksykalny (ważona lista słów kluczowych). Lista termów z wagami pogrupowana według kategorii sygnałów z rulebooka (intencja pierwszoosobowa, marker czasowy, wskazanie celu, gotowość/przygotowanie). Score = znormalizowana suma trafień.

Bez progowania sumy trafień. Dwa warianty scoringu:

- Suma wag trafień.
- Liczba **różnych kategorii** sygnałów, które trafiły (bliższe regule decyzyjnej z rulebooka: ">= 2 sygnały umiarkowane").

Plus jako ablacja:

- Regresja logistyczna na TF-IDF, uczona na małym podzbiorze z etykietami - daje kalibrowane 0-1. Współczynniki to *automatycznie wyprowadzona* lista słów kluczowych.

Przy wariancie z historią definiujemy jawnie regułę agregacji, np. `s = a * score(wpis) + (1-a) * max/mean score(historia)` albo liczba różnych kategorii sygnałów trafionych w całym oknie.

2. Selektor semantyczny (encoder-only + sonda liniowa). Podobieństwo do konkretnego zbioru odniesienia:

- **2a. Zero-shot (kotwice).** Embedujemy wpis i liczymy cosinusowe podobieństwo do małego zbioru kotwic: krótkich opisów sygnałów z rulebooka. Score = max albo średnia po kotwicach. Wynik będzie silnie zależny od doboru kotwic.
- **2b. Sonda uczona.** Zamrożony enkoder, na embeddingach uczymy regresję logistyczną na podzbiorze z etykietami.

Wariant `HISTORY`: uśredniony embedding historii doklejony do embeddingu wpisu (konkatenacja wektorów), oraz konkatenacja tekstów - 2 podejścia.

Do rozważenia

- Czy znalazłyby się inne racjonalne podejścia do 2a?
- Czy istnieje metoda pozwalająca na odtworzenie wartswy tekstowej z embeddingu? Wtedy potencjalne argumenty do przechowywania tylko embeddingów byłyby słabsze.

3. LLM z regułami z pilotażu. Wiadomo.

Do rozważenia

- Modele encoder-only mają małe okno kontekstu. Z pełną historią może dałby radę np. ModernBERT? Czy są inne?
- Jaką mamy heurystykę doboru modeli? Chcemy wykorzystać infrastrukturę CSI, więc powinniśmy sprawdzać modele OS. Ale czy to ma być porównanie closed-source z OS? Same OS? Czy robimy jakieś kontrasty chińskie-nie chińskie? Np. pojedyncza alteracja korpusu z treściami anty-chińskimi? Czy modele chińskie będą działać znacznie gorzej? Wstępnie: kilka modeli w pilocie, jeden później.
- Etykietowanie podzbioru pod selektor 2b: ile wpisów wystarczy? Przy 1% pozytywów sonda potrzebuje kilkuset pozytywów, żeby cokolwiek złapać. Może wymagać oversamplingu przy uczeniu albo doetykietowania.

Metody

Generacja danych

- Przypadki celowe robimy ręcznie (dla korpusu 15 000 wpisów to będzie ledwo ~150 wpisów). Możemy je nawet wziąć żywcem z jakichś serwisów lub istniejącego korpusu. Potrzebny byłby wtedy check poziomu kontaminacji - reguła do przemyślenia, np. "zidentyfikuj autora wpisu / datę napisania".
- Generowanie syntetycznych wpisów okazało się nie takie łatwe. Powinniśmy do tego podejść bardziej metodologicznie. Spróbowałbym tutaj np. wykorzystania techniki *verbalized sampling* (link). Uniwersalnie dobrze działająca metoda generacji syntetycznych wpisów z mediów społecznościowych z jakąś dozą "podejrzaności" mniej lub bardziej uzasadniającą retencję byłaby wkładem naukowym sama w sobie.
- Trzeba nadać autorom stabilną tożsamość stylistyczną i oś czasu. To wydaje mi się dosyć proste. Albo od razu generujemy całą historię wpisów dla pojedynczego autora zgodnie z wytycznymi, albo robimy first pass z generacją pojedynczych wpisów i second pass, gdzie model generujący rozwija nam wpisy do długości całej historii wpisów.

Do rozważenia

- Czy będą gotowe zbiory, które można by wykorzystać? Jeśli tak, to trzeba będzie też sprawdzić poziom kontaminacji.

Ewaluacja

Żaden selektor nie decyduje binarnie. każdy szereguje cały korpus według stopnia uzasadnienia retencji, a my odcinamy górne 1%, 5% i 20%. Porównujemy więc architektury przy równym poziomie ingerencji i dostajemy krzywe: wykrywalności oraz inwazyjności, mierzonej liczbą osób niepowiązanych z niczym, a których dane zostały zatrzymane (czyli mamy wskaźnik, ile trzeba zgromadzić danych niepotrzebnych, aby wykryć jeden potrzebny).

Kamienie milowe

Faza 1: projekt

M1 - decyzje projektowe. Za 2 tygodnie

- Definicja skali i reguły agregacji dla wariantu `HISTORY`.

- Zestaw metryk.
- Protokół antykontaminacyjny na papierze.
- Rozmiar korpusu docelowego.

M2 - pipeline generacji. Za 4 tygodnie

- Implementacja verbalized sampling.
- Generacja tożsamości autorów i osi czasu.
- Próbka 200 wpisów.
- Ręczny przegląd jakości - czy wpisy nie są zbyt jednorodne.

Faza 2: szkielet

M3 - korpus szkieletowy. Za 6 tygodni

- 4000 wpisów, 200 autorów, 10 łuków. Przypadki celowe napisane ręcznie.
- Gold labels dla wszystkich przypadków celowych i dla próbki warstwy okołozagrożeniowej.

M4 - selektory 1-2. Za 9 tygodni

- Selektor leksykalny.
- Selektor semantyczny.
- Pierwsze krzywe wykrywalności i inwazyjności.

M5 - Selektor LLM + pełne porównanie na szkielecie. Za 12 tygodni

- Wszystkie trzy selektory razy dwa warianty.
- Ocena kształtu krzywych.
- Decyzja: skalujemy do 15 000 wpisów, zostajemy przy kilku tysiącach, czy przeprojektowujemy korpus.

Faza 3: skala

M6 - korpus docelowy. Za 17 tygodni

- Pełna skala według decyzji z wcześniej. Trzy warstwy w zadanych proporcjach. 20-40 łuków.
- Kontrola kontaminacji na przypadkach celowych.

M7 - pełny przebieg ewaluacyjny. Za 21 tygodni

- Osiem przebiegów na pełnym korpusie.

- Krzywe przy odcięciach 1% / 5% / 20%.
- Wskaźnik inwazyjności: ilu niepowiązanych autorów zatrzymano na jeden wykryty przypadek.

Faza 4: analiza i pisanie

M8 - testy kontrolne. Za 25 tygodni

- Test biasu, wzorowany na pilotażu.
- Kontrola wspólnej listy cech generatora i selektora.
- Ablacje: lista ręczna kontra regresja logistyczna, kotwice kontra sonda uczona.

M9 - analiza jakościowa. Za 28 tygodni

- Przypadki brzegowe. Które łuki złapał wyłącznie wariant `HISTORY`. Gdzie tańsze architektury przegrywają, a gdzie nie.

M10 - draft artykułu. Za 32 tygodnie

- Pełny szkic z wykresami.